

Predicción y Clasificación de Crisis Epilépticas a partir de EEG usando Técnicas de Machine Learning

Alexander de Jesús Ramírez
Nelson Alcides Puerta

Abstract—La epilepsia es una condición neurológica que puede resultar difícil de controlar y que, en muchos casos, requiere un seguimiento constante para garantizar un manejo adecuado de las crisis que presenta el paciente. En determinadas situaciones, el tratamiento puede llegar a incluir procedimientos quirúrgicos.

Index Terms—epilepsia, EEG, aprendizaje automático, machine learning, clasificación, predicción, BEED, señales biomédicas.

INTRODUCCIÓN

En la actualidad, el diagnóstico y control de esta enfermedad dependen en gran medida de la revisión manual que realizan los neurólogos sobre los exámenes médicos, especialmente los registros de la actividad cerebral. Este proceso es complejo y exige mucho tiempo, lo que dificulta una atención oportuna y continua a todos los pacientes. Por ello, resulta necesario explorar alternativas que faciliten el análisis de la información y apoyen al personal médico en la detección y seguimiento de las crisis epilépticas.

I. DESCRIPCIÓN DEL PROBLEMA

A. Contexto del problema

Se ha observado que las señales producidas por el cerebro presentan diferencias entre las personas que padecen epilepsia y aquellas que no. Estas variaciones pueden analizarse para identificar patrones que indiquen la posible aparición de una crisis.

A partir de este principio, surge la necesidad de desarrollar herramientas que permitan estudiar dichas señales y establecer la probabilidad de ocurrencia de una crisis epiléptica antes de que suceda. De esta manera, sería posible anticipar su aparición y mejorar las estrategias de control y tratamiento, contribuyendo así al bienestar y la seguridad de los pacientes.

B. Composición del dataset

El conjunto de datos utilizado para este estudio está formado por 8 000 muestras y contiene 17 columnas, cada una representando una variable registrada durante el estudio. Las primeras 16 columnas (X1 a X16) corresponden a señales eléctricas captadas por electrodos ubicados en diferentes regiones del cerebro, mientras que la columna restante (y) indica la clase o condición de la persona evaluada.

Todas las variables son de tipo entero (`int64`), y no hay valores faltantes en el conjunto de datos.

C. Configuración del enfoque de aprendizaje

Dado el objetivo de clasificar registros EEG en cuatro categorías clínicas, se seleccionó el paradigma de aprendizaje supervisado, abordando el problema como una tarea de clasificación multiclase. La existencia de etiquetas permite entrenar modelos mediante algoritmos como máquinas de soporte vectorial (SVM), redes neuronales profundas (DNN) o árboles de decisión. Este enfoque se justifica por la naturaleza estructurada del dataset, el balance de clases y la relevancia clínica de identificar cada tipo de crisis epiléptica mediante un proceso automatizado y reproducible. La normalización de datos y la codificación adecuada facilitan la extracción de patrones relevantes y el despliegue de modelos con mayor capacidad generalizadora y robustez ante variaciones individuales de los sujetos.

El problema de clasificación multiclase abordado en este proyecto se enmarca dentro del aprendizaje supervisado tradicional, aunque también puede beneficiarse de extensiones paradigmáticas como el aprendizaje multivista y multimodal si existiesen fuentes de datos adicionales. Para el modelado de los registros EEG, se han considerado arquitecturas de redes neuronales profundas, capaces de aprender representaciones jerárquicas a partir de las señales eléctricas. Específicamente, se emplearon métodos de codificación “label encoding” para la variable objetivo, y se aplicó normalización estándar a las variables de entrada. El diseño técnico contempla el uso de métricas como la precisión global, el macro F1-score, y la matriz de confusión, que permiten una evaluación detallada del desempeño en las cuatro clases. Además, se prestó especial atención a la validación cruzada estratificada, garantizando que la proporción de cada clase se mantuviera en cada partición del conjunto de datos, previniendo sesgos y asegurando una capacidad generalizadora robusta del modelo. Cuando se detectan diferencias artefactuales entre sujetos, se sugiere el uso de técnicas como el análisis de componentes principales (PCA) para reducir la dimensionalidad y facilitar la interpretación de patrones relevantes en la señal.

D. Análisis Exploratorio - Matriz de Correlación

Se realizó un análisis detallado de la matriz de correlación entre los 16 canales EEG (X1 a X16) del dataset BEED. La matriz de correlación cuantifica la relación lineal entre cada par de variables, con valores que oscilan entre -1 y 1, donde valores cercanos a 1 o -1 indican una fuerte correlación positiva o negativa, respectivamente, y valores cercanos a 0 indican ausencia de correlación lineal. Los resultados muestran que la mayoría de los canales presentan correlaciones positivas significativas entre sí, especialmente entre canales adyacentes o cercanos en la configuración del EEG.

Los pares más correlacionados incluyen:

- X2 y X3 con 0.910
- X10 y X11 con 0.905
- X14 y X15 con 0.900
- X6 y X7 con 0.899
- X15 y X16 con 0.888
- X1 y X2 con 0.887
- X7 y X8 con 0.887
- X9 y X10 con 0.886
- X8 y X9 con 0.872
- X13 y X14 con 0.854




Figure 1: Matriz de Correlación

Estas altas correlaciones sugieren que las señales EEG capturadas por canales vecinos tienden a variar de manera similar, lo cual es consistente con la naturaleza espacialmente correlacionada de la actividad cerebral registrada por EEG. Por otro lado, algunos canales muestran correlaciones bajas o cercanas a cero con otros, indicando que ciertas regiones pueden tener actividad más independiente.

El heatmap generado visualiza estas relaciones, destacando las zonas de alta correlación con colores cálidos y las de baja correlación con colores fríos, facilitando la identificación visual de patrones de dependencia entre canales.

Este análisis es fundamental para comprender la redundancia y la estructura de dependencia en los datos EEG, lo que puede guiar la selección de características y la reducción de dimensionalidad en modelos de aprendizaje automático para la detección y clasificación de eventos epilépticos.

II. ESTADO DEL ARTE

Diversos estudios han abordado la clasificación de señales EEG para la detección de eventos epilépticos mediante enfoques

híbridos y técnicas avanzadas de extracción de características.

A. Najmusseher y Banu [1] Los autores introducen el dataset BEED y proponen **SeqBoostNet**, un enfoque híbrido que combina ingeniería de características (FFT, UMAP y estadísticas temporales) con un esquema de boosting. El paradigma utilizado es **aprendizaje supervisado**. La validación se realizó mediante **validación cruzada** sobre BEED. Las métricas empleadas fueron **accuracy**, **F1-score** y **balanced accuracy**, esta última útil en escenarios con clases desbalanceadas. Los resultados reportan mejoras significativas frente a SVM y Random Forest, estableciendo la primera línea base sobre BEED.

B. Zeng et al. [2] Este trabajo desarrolla un método híbrido basado en **CNN** para extracción de representaciones profundas, seguido de reducción de dimensionalidad con **PCA** y clasificación mediante **SVM**. El paradigma es **supervisado** y la validación se realizó con **validación cruzada**. Las métricas utilizadas fueron **F1-score** y **ROC-AUC**, que evalúa la capacidad discriminativa del modelo. Los resultados muestran un F1 cercano a 0.90 y mejoras significativas en ROC-AUC, confirmando el potencial de los modelos híbridos.

C. Slimen et al. [3]

Los autores emplean características tiempo-frecuencia obtenidas mediante **Dual-Tree Complex Wavelet Transform**, combinadas con **SVM** y **k-NN**. El paradigma es **supervisado** y la validación se realizó mediante **validación cruzada** en clasificación binaria. La métrica principal fue **accuracy**, alcanzando valores superiores al 95%, lo que evidencia la robustez de los descriptores wavelet frente al ruido.

D. Kashefi Amiri et al. [4]

Este estudio propone una arquitectura basada en **DWT** y **CNN 1-D**, integrando descomposición wavelet con redes profundas. El paradigma es **supervisado** y se aplicó **validación cruzada** en múltiples datasets públicos. La métrica utilizada fue **ROC-AUC**, obteniendo valores superiores a 0.90 en tareas multicaso, lo que demuestra la efectividad de combinar wavelets con redes profundas.

III. CONFIGURACIÓN EXPERIMENTAL

A. Preprocesamiento de Datos

El dataset BEED fue cargado y las variables predictoras (canales EEG X1 a X16) y la variable objetivo (clase de convulsión) fueron separadas. Se aplicó escalado mediante normalización estándar para centrar y escalar las características, mejorando la convergencia de los modelos. Posteriormente, los datos fueron divididos en conjuntos de entrenamiento (80%) y prueba (20%) usando una división estratificada para mantener la proporción de clases en ambos conjuntos.

B. Metodología de Validación

Para evaluar y ajustar los modelos, se utilizó validación cruzada de 5 pliegues (5-fold) sobre el conjunto de entrenamiento. Esta técnica permite obtener estimaciones robustas del desempeño y evita el sobreajuste.

C. Modelos Evaluados y Ajuste de Hiperparámetros

Se evaluaron cinco modelos de aprendizaje automático representativos de diferentes paradigmas:

- Modelo paramétrico: Regresión logística.
- Modelo no paramétrico: k-Nearest Neighbors (k-NN).
- Ensamble de árboles: Random Forest y Extra Trees.
- Red neuronal artificial: Multi-Layer Perceptron (MLP).
- Máquina de vectores de soporte (SVM).

Para cada modelo, se definió una malla de hiperparámetros que fue explorada mediante búsqueda en cuadrícula (Grid Search) durante la validación cruzada.

Table 1: Hiperparámetros por modelo

Modelo	Hiperparámetro	Valores
Random Forest	árboles(n estimators)	50, 100, 200
SVM	C Kernel	0.1, 1, 10 ln, rbf
Extra Trees	árboles(n estimators)	100, 200
XGBoost	ln-rate max-depth	0.01, 0.05, 0.1
MLP	capas ocultas	64, 128
Voting Classifier	learning-rate	0.01, 0.05

D. Métricas de Desempeño

Para evaluar la calidad de los modelos se utilizaron las siguientes métricas:

- **Accuracy:** Proporción de predicciones correctas sobre el total de muestras. Es una métrica intuitiva pero puede ser engañosa en datasets desbalanceados.
- **F1-score:** Media armónica entre precisión y recall, útil para balancear falsos positivos y falsos negativos, especialmente en problemas con clases desbalanceadas.
- **ROC-AUC:** Área bajo la curva ROC, que mide la capacidad del modelo para discriminar entre clases a diferentes umbrales de decisión.
- **Balanced Accuracy:** Promedio entre sensibilidad y especificidad, que corrige el sesgo de la accuracy en presencia de clases desbalanceadas.

Estas métricas permiten una evaluación completa y equilibrada del desempeño de los modelos en la tarea de clasificación multiclase de señales EEG.

E. Resultados del Entrenamiento

Se presentan los resultados obtenidos para cada modelo evaluado, mostrando el efecto de los hiperparámetros en el desempeño. Las tablas y gráficos incluyen métricas de accuracy, F1-score y ROC-AUC, así como matrices de confusión para analizar errores específicos.

Modelo	Accuracy	Precision	Recall	F1
Random Forest	0.953750	0.953981	0.953750	0.953790
SVM	0.801250	0.798106	0.801250	0.795771
Extra Trees	0.963750	0.963874	0.963750	0.963741
XGBoost	0.947500	0.947776	0.947500	0.947592
MLP	0.893750	0.895101	0.893750	0.894136
Voting	0.955000	0.955118	0.955000	0.955011




Figure 2: Comparación del Accuracy

IV. REDUCCIÓN DE DIMENSIÓN

A. Análisis individual de variables

Se encontró que solo 6 componentes principales son suficientes para explicar la mayor parte de la varianza total de los datos. Esto significa que de las 16 variables originales, solo 6 combinaciones lineales capturan la información más importante.

B. Extracción de características lineal (PCA)

Se realiza la extracción de las 6 componentes principales y se entrenan nuevamente los modelos obteniendo una baja en las métricas que dependiendo del contexto podrían ser considerables.

V. CONCLUSION

Los resultados obtenidos indican que los modelos híbridos constituyen una alternativa particularmente efectiva para la clasificación multiclase de señales EEG en el dataset BEED. La combinación de descomposiciones tiempo-frecuencia con representaciones profundas permite mejorar la separación entre clases fisiológicamente similares, además de incrementar la robustez del sistema frente a artefactos presentes en las señales.

Asimismo, los hallazgos de este estudio son consistentes con tendencias recientes reportadas en la literatura especializada.

	precision	recall	f1-score	support
0	1.00	0.99	1.00	400
1	0.98	0.97	0.98	400
2	0.92	0.94	0.93	400
3	0.94	0.93	0.93	400
accuracy			0.96	1600
macro avg	0.96	0.96	0.96	1600
weighted avg	0.96	0.96	0.96	1600

En particular, los enfoques que integran wavelets y redes convolucionales unidimensionales (CNN 1-D) logran un equilibrio favorable entre interpretabilidad y desempeño, especialmente en escenarios donde los conjuntos de datos presentan variabilidad intersujeto, como es el caso de BEED.

Como línea de trabajo futuro, se plantea la incorporación de arquitecturas basadas en Transformers, mecanismos de atención y técnicas de explicabilidad, con el fin de fortalecer la interpretabilidad clínica y ampliar el alcance de los sistemas de clasificación de EEG.

REFERENCES

VI. REFERENCIAS

- [1] N. Najmousseher and P.K. Nizar Banu, "Feature Engineering for Epileptic Seizure Classification Using SeqBoost-Net," *International Journal of Computing and Digital Systems*, vol.17, no.1, pp. 1–15, 2025, doi: 10.12785/ijcds/1571020131. :contentReference[oaicite:0]index=0 [2] S.A. Karthik, K.N. Bharath, B.R. Ramji, K. Puttegowda, B. Aruna, y D.S. Sunil Kumar, "Enhanced EEG Signal Processing for Accurate Epileptic Seizure Detection," *SN Computer Science*, vol.6, art. no.608, Jul. 2025, doi: 10.1007/s42979-025-04148-1. :contentReference[oaicite:1]index=1 [3] B. Paneru, "Interpretable Machine Learning for Epileptic Seizure Detection on the BEED Using LIME with an Ensemble Network," *preprint*, Oct. 2025, doi: 10.1101/2025.09.30.25336996. :contentReference[oaicite:2]index=2 [4] Y. Hu, J. Liu, R. Sun, Y. Yu, y Y. Sui, "Classification of epileptic seizures in EEG data based on iterative gated graph convolution network," *Frontiers in Computational Neuroscience*, vol.18, article 1454529, Aug. 2024, doi: 10.3389/fncom.2024.1454529. :contentReference[oaicite:3]index=3 [1] J. Arias, "U1. Introducción al Machine Learning," Curso: Introducción al Machine Learning – 2025, Universidad de Antioquia.

CONTENTS

INTRODUCCIÓN	1
1. Descripción del problema	1
1.1. Contexto del problema	1
1.2. Composición del dataset	1
1.3. Configuración del enfoque de aprendizaje.	1
1.4. Análisis Exploratorio - Matriz de Correlación	1
2. Estado del Arte.	2
3. Configuración Experimental	2
3.1. Preprocesamiento de Datos	2
3.2. Metodología de Validación	2
3.3. Modelos Evaluados y Ajuste de Hiperparámetros.	3
3.4. Métricas de Desempeño	3
3.5. Resultados del Entrenamiento	3
4. Reducción de dimensión.	3
4.1. Análisis individual de variables	3
4.2. Extracción de características lineal (PCA)	3
5. Conclusion	3
6. Referencias	4
References.	4